analyse groupe de variables

```
load("../.RData")
require(knitr)
## Loading required package: knitr
## Warning: package 'knitr' was built under R version 3.5.2
colnames(dataPropre)
##
  [1] "Experimentateur" "Pedagogie"
                                             "Classe"
## [4] "TypeClasse"
                           "Sexe"
                                             "Langues"
## [7] "Lateralite"
                                             "DateEval"
                           "DateNaissance"
## [10] "AgeChar"
                           "AgeNum"
                                             "AgeInt"
                           "T21"
                                             "T22"
## [13] "T1"
                                             "T32"
## [16] "T23"
                           "T31"
## [19] "T41a"
                           "T41b"
                                             "T41c"
## [22] "T41d"
                           "T42a"
                                             "T42b"
## [25] "T42c"
                                             "T51"
                           "T42d"
## [28] "T52"
                           "T61"
                                             "T62"
## [31] "T71"
                                             "T81"
                           "T72"
                           "T83"
## [34] "T82"
                                             "T84"
## [37] "T85"
                           "T86"
                                             "T87"
## [40] "T88"
                           "T89"
                                             "AnneeScolaire"
noms<-c("T23","T31","T52","T62","T86","T87","T88","T89","T42a","T42b","T42c","T42d")
audela <-rowSums (apply (dataPropre[,noms],2,as.numeric)) #somme de chaque question concerné par la var aud
audela<-audela+ifelse(dataPropre$T1>7,1,0)#ajout de la t1 si ils savent compter au dela de 7
noms<-c("T41a","T41b","T41c","T41d","T42a","T42b","T42c","T42d","T51","T52","T62","T61")
outils<-rowSums(apply(dataPropre[,noms],2,as.numeric))</pre>
noms<-c("T21","T22","T23","T31","T32","T81","T82","T83",
       "T84", "T85", "T86", "T87", "T88", "T89")
objet<-rowSums(apply(dataPropre[,noms],2,as.numeric))
```

Etude du chi2 de chaque variable du groupe au dela chacune entre elles

```
noms<-c("T23","T31","T52","T62","T86","T87","T88","T89","T42a","T42b","T42c","T42d")
res.chi2<-matrix(nrow = length(noms),ncol = length(noms))
colnames(res.chi2)<-noms
row.names(res.chi2)<-noms
for (i in 1:length(noms)){
   for (j in 1:length(noms)){
     res.chi2[i,j]<-chisq.test(table(dataPropre[,noms[i]],dataPropre[,noms[j]]))$p.value
}
kable(ifelse(res.chi2>10**-5,"0","1"))
```

	T23	T31	T52	T62	T86	T87	T88	T89	T42a	T42b	T42c	T42d
T23	1	1	0	0	0	0	1	0	0	0	0	0

	T23	T31	T52	T62	T86	T87	T88	T89	T42a	T42b	T42c	T42d
T31	1	1	0	0	1	1	1	1	0	0	1	0
T52	0	0	1	0	0	0	0	0	0	0	0	0
T62	0	0	0	1	0	0	0	0	0	0	0	0
T86	0	1	0	0	1	1	1	1	0	0	0	0
T87	0	1	0	0	1	1	1	1	0	0	0	0
T88	1	1	0	0	1	1	1	1	0	0	0	0
T89	0	1	0	0	1	1	1	1	0	1	0	0
T42a	0	0	0	0	0	0	0	0	1	1	0	1
T42b	0	0	0	0	0	0	0	1	1	1	1	1
T42c	0	1	0	0	0	0	0	0	0	1	1	1
T42d	0	0	0	0	0	0	0	0	1	1	1	1

Un "1" et mis dans les cases qui sont significatives afin que le tableau soit plus facilement lisible. On peut voir que les couples de variables qui ont un chi2 significatif sont : T21 T22, T22 T32, T84 T22, T84 T21, T83 T22, T85 T32, et toutes les T8 entre elles.

Création des groupes sur la Q1

```
Classe_T1<-cut(dataPropre$T1,breaks = c(-1,3,7,11,16,100))
levels(Classe_T1)<-c(1/3,2/3,1,4/3,5/3)
Classe_T1<-as.numeric(Classe_T1)
don.groupe<-data.frame(Pedagogie=dataPropre$Pedagogie,Classe_T1,audela,outils,objet)</pre>
```

Regression sur les nouveaux groupes

```
# req<-qlm(Pedagogie~.,data = don.groupe,family = binomial)</pre>
# step(reg) ##on ne garde que la regression avec le regroupement "au dela" les autres ne sont pas signi
reg<-glm(Pedagogie~audela,data = don.groupe,family = binomial)</pre>
summary(reg)##audela significatif avec la pédagogie
##
## Call:
## glm(formula = Pedagogie ~ audela, family = binomial, data = don.groupe)
##
## Deviance Residuals:
##
       Min
                 1Q
                      Median
                                   3Q
                                           Max
## -1.2743 -0.9914 -0.8320
                               1.2978
                                        1.6133
##
## Coefficients:
               Estimate Std. Error z value Pr(>|z|)
##
## (Intercept) -0.98361
                           0.30651
                                    -3.209 0.00133 **
## audela
                0.10071
                           0.04929
                                     2.043 0.04101 *
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##
       Null deviance: 207.88 on 155 degrees of freedom
## Residual deviance: 203.62 on 154 degrees of freedom
## AIC: 207.62
##
```

```
## Number of Fisher Scoring iterations: 4
```

Seule la variable audela est significative, afin de prédire la pédagogie. On peut donc dire que les question de type "audela" peuvent définir un élève classique d'un élève montessorien.

La partie suivante consiste à créer un échantillon sur lequel refaire le même modèle, pour ensuite prédire la pédagogie sur le reste du jeu de données. Cependant un problème est rencontré : le modèle n'est plus adéquate, la variable n'est pas significative..

```
if (!require("ResourceSelection")) install.packages("ResourceSelection")

## Loading required package: ResourceSelection

## Warning: package 'ResourceSelection' was built under R version 3.5.3

## ResourceSelection 0.3-4 2019-01-08

require(ResourceSelection)
hoslem.test(don.groupe$Pedagogie,fitted(reg))

## Warning in Ops.factor(1, y): '-' not meaningful for factors

##

## Hosmer and Lemeshow goodness of fit (GOF) test

##

## data: don.groupe$Pedagogie, fitted(reg)

## X-squared = 156, df = 8, p-value < 2.2e-16</pre>
```

Le test de hosmer-Lemeshow nous donne une pvalue significative, il y a donc une différence entre le modèle et les données observées, le modèle ne serait donc pas adéquate...

Réalisation du modèle sur un échantillon :

```
train.id<-sample(seq_len(nrow(don.groupe)),size = 109)
don.train<-don.groupe[train.id,]
don.test<-don.groupe[-train.id,]</pre>
```

Réalisation du modèle :

```
reg<-glm(Pedagogie~Classe_T1,data = don.train,family = binomial)
summary(reg)
##
## Call:</pre>
```

```
## glm(formula = Pedagogie ~ Classe_T1, family = binomial, data = don.train)
##
## Deviance Residuals:
      Min
                1Q
                    Median
                                  3Q
                                          Max
## -1.1489 -0.9760 -0.8187
                              1.2988
                                        1.5850
##
## Coefficients:
              Estimate Std. Error z value Pr(>|z|)
##
## (Intercept) -1.1344
                           0.4757
                                  -2.385
                                            0.0171 *
## Classe_T1
                0.2134
                           0.1358
                                    1.572
                                            0.1160
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
```

```
##
## Null deviance: 145.32 on 108 degrees of freedom
## Residual deviance: 142.80 on 107 degrees of freedom
## AIC: 146.8
##
## Number of Fisher Scoring iterations: 4
```